

CIENCIA DE DATOS FINANCIERA · SESIONES 7 → 8

De la minería de datos a la valoración con LLMs

Cómo una máquina aprendió a leer textos financieros, y cómo usamos esa lectura para valorar una empresa

LA PREGUNTA DE FONDO

¿Esta frase sugiere que la acción debería subir, bajar o quedarse igual?



Todos los métodos de hoy calculan **esta misma función**. Lo que cambia, década tras década, es **cómo** la calculan.

EVOLUCIÓN

Tres décadas para que una máquina aprendiera a leer

1990s	2000s	2011	2013	2017–18	2019	2020–hoy
Minería de datos	Minería de texto	Diccionario financiero	Embeddings	Transformers y BERT	FinBERT	LLMs y RAG
Patrones en tablas: scoring, ratios, KDD	El texto se vuelve una matriz de palabras	Loughran y McDonald: palabras con sentido financiero	word2vec: palabras como vectores	Atención: el contexto cambia el significado	BERT afinado con texto financiero	Seguir instrucciones, leer documentos y citarlos

Hitos: KDD 1996 · Loughran-McDonald 2011 · word2vec 2013 · Transformer 2017 · BERT 2018 · FinBERT 2019 · RAG 2020

EVOLUCIÓN

De las tablas al texto

MINERÍA DE DATOS · LO QUE YA HICIERON

Datos estructurados

- Estados financieros, precios, variables de crédito
- Cada fila es una empresa o un cliente; cada columna, una variable
- Logística, árboles, XGBoost (Sesiones 4–6)

MINERÍA DE TEXTO · LO NUEVO

Datos no estructurados

- Noticias, 10-K, informes de gestión, llamadas con analistas
- No hay columnas: hay palabras, orden y contexto
- Reto: convertir el texto en números

Si convertimos el texto en números, **todo lo que ya saben de machine learning vuelve a servir.**

LA ESCALERA DEL SENTIMIENTO · UNA FRASE, CUATRO LECTURAS

“ Operating income decreased 5.7% to \$662 million.”

La utilidad operativa cayó 5,7 % a USD 662 millones. Para un inversionista: **negativa**:

1 · Diccionario


1b · Matriz + ML

2–3 · FinBERT

4 · LLM

Contar palabras con un diccionario financiero

- 1. Tokenizar:** minúsculas, solo letras (los números desaparecen)
- 2. Buscar** cada token en la lista positiva y en la negativa
- 3. Decidir por mayoría;** empate = neutral



“decreased” no está en la lista negativa (sí están “decline” y “declined”)

0 positivas · 0 negativas → neutral

Error: la frase es negativa

Ventaja: transparente y gratis. Límite: **depende de la palabra exacta** y no entiende negaciones (“profits did not decline”).

El texto como matriz una fila por frase, una columna por palabra

Frase	costs	decreased	income	increased	Etiqueta
Operating income decreased	0	1	1	0	negativa
Net income increased	0	0	1	1	positiva
Costs decreased	1	1	0	0	positiva

Con la matriz (conteos o **TF-IDF**) se entrena **la misma regresión logística del scoring**.

Los pesos de cada palabra salen de los datos, no de una lista hecha a mano.

Límite: el orden se pierde. “Costs decreased” e “income decreased” comparten la misma columna *decreased*, aunque una sea buena noticia y la otra mala.


Embeddings: palabras como puntos en un espacio

Un **embedding** es un vector de números aprendido de tal forma que **palabras con significado parecido quedan cerca**.

ANALOGÍA FINANCIERA

Como un modelo de factores resume una acción en pocas coordenadas (tamaño, valor, momentum), el embedding resume una palabra en coordenadas latentes.

En el cuaderno: 384 dimensiones (MiniLM), proyectadas a 2D con PCA. Nadie programó los grupos: emergen del entrenamiento.



Ilustrativo: azul, resultados favorables · naranja, dificultad financiera

Atención: el significado depende del contexto

Costs

decreased

8%

→ **Positiva: bajan los costos**

Operating income

decreased

5.7%

→ **Negativa: cae la utilidad**

Profits

did not decline

→ **No negativa: la negación se lee como unidad**

Para cada palabra, la atención calcula **cuánto debe “mirar” a las demás**. Así *decreased* junto a *costs* significa algo distinto que junto a *income*: es lo que hace un analista sin pensarlo.

Cuatro pasos de la frase a las probabilidades



Salida para "Operating income decreased 5.7% to \$662 million" (valores ilustrativos)



FinBERT no sigue reglas: **aprendió de miles de frases financieras etiquetadas** (preentrenamiento + afinamiento).

LLM generativo: de clasificar a seguir instrucciones

	Encoder (FinBERT)	Decoder (Qwen, GPT)
Objetivo	Entender la frase	Generar texto
Tareas	Una, fija	Cualquiera (prompt)
Explica	Solo probabilidades	Justifica en texto
Costo	Bajo, rápido	Mayor, token a token

PROMPT

Eres un analista financiero. Responde SOLO con JSON: sentimiento y justificacion.

RESPUESTA

```
{"sentimiento": "negative", "justificacion": "La utilidad operativa operativa cayó 5,7%."}
```

Zero-shot: solo la instrucción

Few-shot: instrucción + ejemplos resueltos

Parser robusto: nunca confiar ciegamente

Ojo: la justificación puede ser post hoc

¿Cómo sabemos cuál método funciona mejor?

Accuracy

Engañosa: en PhraseBank más de la mitad de las frases son neutrales. Decir “neutral” siempre ya da una cifra alta.

F1 macro

Promedia las tres clases con el mismo peso: castiga al modelo que ignora negativas y positivas.

Matriz de confusión

No todos los errores cuestan igual: confundir negativa con positiva es mucho más grave que con neutral.

Regla de oro: los cuatro métodos se evalúan sobre **la misma muestra**, para que la comparación sea justa.

No gana un método: cada uno tiene su lugar

Criterio	Diccionario	FinBERT	LLM
Costo por frase	Casi nulo	Bajo	Medio-alto
Velocidad	Muy alta	Alta	Baja-media
Interpretabilidad	Total	Parcial	Alta, pero post hoc
Necesita GPU	No	Ayuda	Casi siempre
Tareas nuevas	No	No	Sí, con el prompt
Otros idiomas	Con otro diccionario	No (inglés)	Sí, en distinto grado

En la práctica se combinan: **FinBERT para el volumen diario** y **el LLM para casos ambiguos, tareas nuevas o lectura a fondo**, como un 10-K.

Alucinación: preguntar de memoria o extraer del documento

DE MEMORIA

“¿Cuál fue el EBITDA de Grupo Argos en el tercer trimestre de 2023?”

Una cifra concreta, en tono seguro, imposible de distinguir de una real sin ir a la fuente.

DEL DOCUMENTO

“Según este texto, ¿cuál fue el EBITDA de ACME S.A.?”

La cifra está en el contexto: la tarea es extraer, no recordar. Verificable contra la fuente.

En finanzas, el LLM trabaja **sobre documentos que nosotros le entregamos**, y toda salida se verifica antes de usarse. antes de usarse.

Ya sabemos leer una frase.

¿Y si en vez de un titular tenemos un **10-K de 200 páginas?**

No cabe en el modelo: hay que segmentar y recuperar
El valor está en el cambio: qué riesgos son nuevos

Las cifras importan al decimal: hay que verificar
El LLM no valora: lee y cita; el analista decide

EL MODELO DE REPORTES

Del 10-K a la nota de valoración, en seis pasos



APLICACIÓN A VALORACIÓN

En el DCF, cada quien hace lo suyo

Elemento del DCF	Fuente	Quién decide
Ingresos, EBIT, D&A, capex, caja, deuda	XBRL de la SEC	El dato
Guía de crecimiento, presión de margen, riesgos	Texto, leído con citas verificadas	El LLM, verificable
Cómo la lectura se vuelve supuestos	Tabla REGLAS, a la vista	El analista
WACC base y crecimiento terminal	Curso de valoración	El analista

Ninguna cifra del DCF sale del LLM. Si un comité pregunta “¿por qué este WACC?”, la respuesta está en una celda, no en una caja negra.

PARA DISCUTIR

Cuatro preguntas antes del taller

1

¿Por qué “costs decreased” es positiva y “revenue decreased” negativa, si la palabra clave es la misma?

2

Si FinBERT dice que la mitad de las oraciones de Risk Factors son negativas, ¿es una mala noticia?

3

¿Usarían el sentimiento directamente como supuesto del DCF? ¿Qué falta en medio?

4

¿Qué método elegirían para 10.000 noticias diarias, y cuál para leer a fondo un solo 10-K?