

# Optimización de portafolios de Inversión

## Construcción de Visiones BL

Docente: Natalia Acevedo Prins

E-mail: [natalia.acevedop@udea.edu.co](mailto:natalia.acevedop@udea.edu.co)

Maestría en Métodos Cuantitativos para Economía y Finanzas

Facultad de Ciencias Económicas.

Universidad de Antioquia

# Perspectivas tácticas-Matriz P

$$\mu^{BL} = [(\tau\Sigma)^{-1} + P^T \Omega^{-1} P]^{-1} [(\tau\Sigma)^{-1} \Pi + \boxed{P^T \Omega^{-1} Q}] \longrightarrow \text{Visiones}$$

Codificar la Visión k (Fila k):

- ✓ Si la visión es absoluta al activo le corresponde un 1 y 0 a los demás activos
- ✓ Si la visión es relativa se compara el activo con otro. El "ganador" recibe signo positivo y el "perdedor" signo negativo.

La matriz  $P$  tendrá dimensiones  $k \times n$ , donde  $k$  = número de visiones y  $n$  = número de activos.

## Ejemplo:

Tenemos un portafolio con 4 activos:

AAPL ,TSLA , XOM y GLD (Oro)

$A = [AAPL, TSLA, XOM, GLD]$

## 2 Visiones:

Visión 1 (Absoluta): "Creemos que el Oro (GLD) tendrá un rendimiento del 5%" (Basado en un pronóstico de baja volatilidad y estabilidad).

Visión 2 (Relativa): "Creemos que el sector tecnológico (AAPL y TSLA) superará al sector energía (XOM) en un 2%" (Basado en una rotación de activos).

# Perspectivas tácticas-Matriz P

**Codificar la Visión 1 (Fila 1):** Como es una visión absoluta sobre el cuarto activo (GLD), ponemos un 1 en la cuarta columna y 0 en las demás:

*Fila 1:* [0, 0, 0, 1]

**Codificar la Visión 2 (Fila 2):** Como es una visión relativa, comparamos grupos. El grupo "ganador" (tecnológico) recibe signo positivo y el "perdedor" (Energía) signo negativo.

Tenemos 2 activos en el grupo ganador ( $1/2 = 0.5$  para cada uno) y 1 activo en el perdedor (-1).

*Fila 2:* [0.5, 0.5, -1, 0]

**Matriz  $P$  (Picking):**

$$P = \begin{bmatrix} 0 & 0 & 0 & 1 \\ 0.5 & 0.5 & -1 & 0 \end{bmatrix}$$

**Vector  $Q$  (Rendimientos de las Visiones):**

$$Q = \begin{bmatrix} 0.05 \\ 0.02 \end{bmatrix}$$

**View 1:**

$$(0 \cdot R_{AAPL}) + (0 \cdot R_{TSLA}) + (0 \cdot R_{XOM}) + (1 \cdot R_{GLD}) = 0.05$$

**View 2:**

$$(0.5 \cdot R_{AAPL}) + (0.5 \cdot R_{TSLA}) + (-1 \cdot R_{XOM}) + (0 \cdot R_{GLD}) = 0.02$$

\*sumar 0 en vistas relativas  $0.5 + 0.5 - 1 = 0$  asegura que la visión capture únicamente el diferencial.

# Calibración de la Matriz de Incertidumbre $\Omega$

Determina cuánta importancia le dará el optimizador a tu visión frente al equilibrio de mercado.  $\Omega$  es una matriz diagonal de  $k \times k$ .

## Enfoque 1: Varianza del Error de Pronóstico

Si se utiliza un modelo estadístico para volatilidad, la incertidumbre de tu visión debe ser la varianza del error de ese modelo en el pasado:

$$\omega_j = \text{Var}(\sigma_{\text{real}} - \sigma_{\text{forecast}})$$

Si tu modelo de volatilidad es muy preciso  $\omega_j$  será pequeño y el modelo BL seguirá tu visión casi estrictamente.

## Enfoque 2: Método de Proporcionalidad de Idzorek

Se asume que la incertidumbre de la visión es proporcional a la varianza del activo escalada por el parámetro  $\tau$  (sensibilidad del apriori)

$$\omega_j = \alpha \cdot (p_j \Sigma p_j^T)$$

Donde:

$\omega_j$ : Importancia para el optimizador

$p_j$ : Fila  $j$  de la matriz  $P$ .

$\Sigma$ : Matriz de covarianza de los activos.

$\alpha$ : Un escalar que representa tu nivel de desconfianza (si  $\alpha$  es alto, la visión se ignora).

# Rendimientos de las perspectivas



## 1. Modelos de Series de Tiempo (Econometría Clásica)

Intentan capturar la persistencia y la media de los rendimientos.

- ✓ **ARIMA / SARIMA:** Captura tendencias claras o estacionalidad
- ✓ **Modelos de Reversión a la Media:** estrategias de valor relativo
- ✓ **ARCH-GARCH:** Proyecta volatilidad

## 2. Modelos de Factores (Asset Pricing)

Enfoque Fundamental

- ✓ **Modelo de Fama-French:** Rendimiento esperado basado en el tamaño, el valor y la calidad
- ✓ **Vistas Macro:** sensibilidad ( $\beta$ ) a algún indicador macroeconómico.

## 3. Machine Learning y Deep Learning (Análítica Avanzada)

Es la tendencia actual en los Hedge Funds.

- ✓ **Random Forest / XGBoost:** clasificar si un activo tendrá un rendimiento superior o inferior.
- ✓ **Redes LSTM:** detectan patrones no lineales que los modelos ARIMA ignoran.
- ✓ **NLP:** analizan noticias y reportes para generar un análisis de sentimientos.

# Modelos de Volatilidad

- ✓ Los rendimientos financieros no son independientes ni idénticamente distribuidos (i.i.d.).
- ✓ Presentan agrupación de volatilidad: periodos de alta calma seguidos de periodos de alta turbulencia.
- ✓ Esto implica que la varianza no es constante (Heterocedasticidad) y depende de la información pasada.

## Modelo ARCH:

$$\sigma_t^2 = \omega + \sum_{i=1}^p \alpha_i r_{t-i}^2,$$

Introducido por Robert Engle en 1982. Propone que la varianza de hoy es una función ponderada de los shocks cuadrados pasados (errores de predicción).

## Modelo ARCH:

$$\sigma_t^2 = \omega + \sum_{i=1}^q \alpha_i r_{t-i}^2 + \sum_{j=1}^p \alpha_j \sigma_{t-j}^2$$

Bollerslev (1986) añadió una "Memoria de Largo Plazo". La varianza de hoy depende de los shocks pasados Y de la varianza de ayer.