

Optimización de portafolios de Inversión

El Enfoque Black-Litterman.

Docente: Natalia Acevedo Prins

E-mail: natalia.acevedop@udea.edu.co


Maestría en Métodos Cuantitativos para Economía y Finanzas

Facultad de Ciencias Económicas.

Universidad de Antioquia


¿Por qué no usar solo Markowitz?

- ✓ La optimización estándar de media-varianza tiene un comportamiento errático porque **no son observables** y deben estimarse a partir de datos históricos.
- ✓ Pequeñas inconsistencias en los pronósticos pueden llevar al optimizador a crear portafolios con apalancamiento excesivo o posiciones cortas irrazonables.



Contracción de Ledoit-Wolf

El estimador de Ledoit-Wolf: propone combinar la matriz de covarianza de la muestra con una matriz objetivo más simple (como una donde todas las correlaciones sean iguales). Wolf propone la matriz identidad



El estimador de Ledoit-Wolf busca el α^* que minimiza el error cuadrático medio (ECM) entre el estimador shrinkage y la verdadera matriz de covarianza poblacional:

$$\alpha^* = \arg \min_{\alpha} E \left[\| \alpha F + (1 - \alpha) \hat{\Sigma} - \Sigma \|_F^2 \right]$$

donde $\|\cdot\|_F$ es la norma de Frobenius.

$$\|A\|_F := (\text{tr}(A^* A))^{1/2}$$

Los estimadores de contracción para la covarianza siempre producen matrices definidas positivas y bien condicionadas, lo que resulta en una **mejor diversificación de los pesos** y **mayor estabilidad out-of-sample**.

Fórmula de Ledoit-Wolf 2004

Al expandir el ECM y derivar respecto a α , se obtiene una solución analítica cerrada:

$$\alpha^* = \frac{\sum_{i,j} \text{Var}(\hat{\sigma}_{ij})}{\sum_{i,j} E[(\hat{\sigma}_{ij} - f_{ij})^2]}$$

Intuitivamente:

Componente	Significado
Numerador	Suma de las varianzas de cada entrada de $\hat{\Sigma}$ (cuánto "ruido" tiene la covarianza muestral)
Denominador	Distancia cuadrada total entre $\hat{\Sigma}$ y el target F (cuánto difieren)

Se estiman tres cantidades a partir de los datos $x_1, \dots, x_T$ (cada uno un vector de N activos):

β : variabilidad de las entradas muestrales (estimada con momentos de 4to orden):

$$\hat{\beta} = \frac{1}{T^2} \sum_{t=1}^T \|x_t x_t^\top - \hat{\Sigma}\|_F^2$$

δ — distancia entre la covarianza muestral y el target:

$$\hat{\delta} = \|\hat{\Sigma} - F\|_F^2$$

α óptimo:

$$\alpha^* = \frac{\min(\hat{\beta}, \hat{\delta})}{\hat{\delta}}$$

Fórmula de Ledoit-Wolf 2004

Interpretación:

- Si $\hat{\beta}$ es **grande** (mucho ruido en $\hat{\Sigma}$) $\rightarrow \alpha$ es alto $\rightarrow$ más contracción hacia F .
- Si $\hat{\beta}$ es **pequeño** (buena estimación muestral) $\rightarrow \alpha$ es bajo $\rightarrow$ se confía más en $\hat{\Sigma}$.
- Si $\hat{\delta}$ es **grande** ($\hat{\Sigma}$ y F son muy distintas) $\rightarrow$ el denominador crece $\rightarrow \alpha$ baja, porque forzar hacia F introduciría mucho sesgo.


F es una matriz proporcional a la identidad:

$$F = \bar{\sigma}^2 \cdot I_N, \bar{\sigma}^2 = \frac{\text{tr}(\hat{\Sigma})}{N}$$

Es decir, asume varianzas iguales y covarianzas cero — el prior más "agnóstico" posible.

Estabilidad a través del Equilibrio.


El modelo Black-Litterman utiliza el equilibrio del CAPM como un "centro de gravedad" para la estimación de rendimientos actúa como un punto neutral que mejora las propiedades estadísticas de los estimadores a través de un ajuste.



✓ A diferencia de los métodos tradicionales, Black-Litterman garantizó con su modelo que, en ausencia de visiones específicas, el inversionista mantenga el portafolio de capitalización de mercado

Modelo Black - Litterman

Permite centrarse en una o más visiones tácticas sobre portafolios específicos.



El modelo reformula el problema del inversionista:
no se pide especificar un vector completo de rendimientos para cada activo.

- ✓ Introduce un grado de confianza a la desviación estándar para cada visión, reconociendo que la información es incierta.

El Proceso de Black-Litterman.

El modelo combina estas fuentes de información, ambas expresadas como distribuciones de probabilidad, para generar un nuevo vector de rendimientos esperados que impulse la optimización

Fundamento: enfoque bayesiano

Enfoque bayesiano

$= \text{Posterior} \propto \text{Prior} + \text{Información nueva}$

Prior $\rightarrow$ equilibrio de mercado

Información nueva $\rightarrow$ visiones

Proceso del Modelo Black-Litterman

1. Estimar la Matriz de Covarianza (Σ) 

2. Obtener los Pesos de Mercado (w^{mkt}) 

3. Calcular los Rendimientos de Equilibrio (π)

4. Definir la Matriz de Opiniones (P) 

5. Definir el Vector de Opiniones (Q) 

6. Determinar la Incertidumbre (Ω) 

7. Elegir el Parámetro τ

8. Calcular los Rendimientos Actualizados (μ^{BL})

9. Calcular los Rendimientos Actualizados (μ^{BL})

9. Optimizar el Portafolio 

Rendimientos de equilibrio (π)

Es el retorno que hace que el portafolio de mercado sea óptimo bajo CAPM.

$$\Pi = \delta \Sigma w^{mkt}$$

Recordando el CAPM

Donde:

Π : vector de rendimientos implícitos (equilibrio)

δ : aversión al riesgo

Σ : matriz de covarianza

w^{mkt} : pesos de mercado

$$\delta = \frac{E[R_m] - R_f}{\sigma_m^2}$$

Donde:

- ✓ $E[R_m]$: retorno esperado del mercado
- ✓ R_f : tasa libre de riesgo
- ✓ σ_m^2 : varianza del mercado

Cuantificación de Perspectivas Tácticas.

Visiones del inversionista

Se modelan como:

$$P\mu = Q + \varepsilon$$

Donde:

P : matriz de exposición de visiones

Q : retornos esperados de las visiones

$\varepsilon \sim N(0, \Omega)$: error

Matriz de incertidumbre (Ω)

$$\Omega = \text{Cov}(\varepsilon)$$

Diagonal normalmente

Controla la confianza

Nueva matriz de covarianza nueva

$$\Sigma^{BL} = \Sigma + [(\tau\Sigma)^{-1} + P^T\Omega^{-1}P]^{-1}$$

Detalles técnicos:

- ✓ P : Matriz que especifica los activos incluidos en cada visión
- ✓ Q : Vector con los rendimientos esperados de los portafolios de visión
- ✓ Ω : Matriz de covarianza que representa la incertidumbre o confianza en las visiones

Tipos de visiones:

Absolutas:

$$\mu_i = 0.08$$

Relativas:

$$\mu_A - \mu_B = 0.03$$

Ejemplo: Una visión bajista sobre el mercado alemán se expresa como una posición corta de valor q con un nivel de confianza definido

Si el inversor no tiene perspectivas, el modelo BL devuelve la cartera de mercado.

Es un punto de partida neutral y robusto.

Herramientas para perspectivas e Incertidumbre

Metodología	Insumo Principal	Ventaja	Complejidad
Fundamental	Reportes de Analistas	Intuitivo y explicable	Baja
Macro-Regímenes	Indicadores Líderes	Captura cambios de ciclo	Media
Machine Learning	Datos Históricos	Identifica relaciones no lineales	Alta
NLP / LLMs	Noticias y Texto	Captura información en tiempo real	Muy Alta

El Estimador Maestro.

$$\mu^{BL} = [(\tau \Sigma)^{-1} + P^T \Omega^{-1} P]^{-1} [(\tau \Sigma)^{-1} \Pi + P^T \Omega^{-1} Q]$$

Parámetro τ (tau)

$\tau \Sigma$

✓ Escala la incertidumbre del prior

Determina cuánto se confía en el equilibrio,

Si $\tau \rightarrow 0$: Confiamos plenamente en el equilibrio (el mercado es eficiente).

Si $\tau \rightarrow \infty$: El equilibrio no tiene peso; solo importan las *views*.

Optimización final

Se reemplaza en Markowitz:

$$w^* = \arg \min_w (w^T \Sigma w - \lambda w^T \mu^{BL})$$

La lógica de Thomas Idzorek:

En lugar de fijar τ , definimos un "Nivel de Confianza" del 0% al 100% para cada vista. El modelo entonces calcula internamente los valores de Ω que, dado un τ fijo (generalmente 1), desplazan los pesos de la cartera exactamente lo que el usuario desea.

Ejemplo numérico

Consideremos **3 activos**:

Activo	Peso de mercado
A	0.5
B	0.3
C	0.2

Matriz de covarianza

$$\Sigma = \begin{bmatrix} 0.10 & 0.02 & 0.04 \\ 0.02 & 0.08 & 0.01 \\ 0.04 & 0.01 & 0.09 \end{bmatrix}$$

Parámetro de aversión al riesgo

$$\delta = 2.5$$

Incertidumbre del prior $\tau = 0.05$

Definición de visiones

Supongamos:

✓ Vista 1 (relativa):

A tendrá 3% más retorno que B

✓ Vista 2 (absoluta):

C tendrá retorno esperado de 8%

Matriz P

$$P = \begin{bmatrix} 1 & -1 & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

Vector Q

$$Q = \begin{bmatrix} 0.03 \\ 0.08 \end{bmatrix}$$

Confianza en las visiones (Ω)

Supongamos:

$$\Omega = \begin{bmatrix} 0.0025 & 0 \\ 0 & 0.0016 \end{bmatrix}$$

Menor valor = mayor confianza

Solución

Paso 1. Rendimientos de equilibrio (Π)

Usamos:

$$\Pi = \delta \Sigma w^{mkt}$$

Cálculo:

Primero:

$$\Sigma w = \begin{bmatrix} 0.1(0.5) + 0.02(0.3) + 0.04(0.2) \\ 0.02(0.5) + 0.08(0.3) + 0.01(0.2) \\ 0.04(0.5) + 0.01(0.3) + 0.09(0.2) \end{bmatrix} = \begin{bmatrix} 0.064 \\ 0.036 \\ 0.041 \end{bmatrix}$$

Entonces:

$$\Pi = 2.5 \cdot \begin{bmatrix} 0.064 \\ 0.036 \\ 0.041 \end{bmatrix} = \begin{bmatrix} 0.160 \\ 0.090 \\ 0.1025 \end{bmatrix}$$

Paso 2: Inversa de $\tau \Sigma$

(no hacemos manual completo en clase, se usa software)

Resultado aproximado:

$$\left(\tau \Sigma \right)^{-1} \approx \begin{bmatrix} 250 & -40 & -90 \\ -40 & 300 & -20 \\ -90 & -20 & 280 \end{bmatrix}$$

Paso 3: Ω^{-1}

$$\Omega^{-1} = \begin{bmatrix} 400 & 0 \\ 0 & 625 \end{bmatrix}$$

Solución

Paso 4: $P^T \Omega^{-1} P$

Resultado:

$$P^T \Omega^{-1} P = \begin{bmatrix} 400 & -400 & 0 \\ -400 & 400 & 0 \\ 0 & 0 & 625 \end{bmatrix}$$

Paso 5: Suma de matrices

$$M = (\tau \Sigma)^{-1} + P^T \Omega^{-1} P$$

Paso 6: Segundo término

$$b = (\tau \Sigma)^{-1} \Pi + P^T \Omega^{-1} Q$$

Resultado final (aproximado)

$$\mu^{BL} \approx \begin{bmatrix} 0.145 \\ 0.115 \\ 0.085 \end{bmatrix}$$

Activo	Π (equilibrio)	μ^{BL}
A	0.160	0.145 ↓
B	0.090	0.115 ↑
C	0.102	0.085 ↓

La vista A > B hace que:

B suba (relativo)

A se ajuste

La vista sobre C reduce su retorno esperado

Todo está suavizado (shrinkage) hacia el equilibrio

Solución

Paso 7: Optimización final

Con estos nuevos retornos:

$$w^* = \underset{w}{\operatorname{argmin}}(w^T \Sigma w - \lambda w^T \mu^{BL})$$

Resultado:

Portafolio más estable

Menos extremos

Coherente con visiones

¿Por qué es indispensable?

Black–Litterman es una combinación compleja de:

- ✓ Equilibrio (CAPM)
- ✓ Opiniones (views)
- ✓ Confianza (Ω)

- ✓ Produce portafolios equilibrados y con sentido común incluso con restricciones.
- ✓ Ajusta todos los rendimientos de manera consistente, no solo los de los activos en la visión, basándose en sus correlaciones
- ✓ Es la herramienta ideal cuando existen restricciones de riesgo, apalancamiento o exposición de mercado.